

Reconstrucción de Puntuación y Capitalización en Texto Plano mediante Aprendizaje Automático

Luciano Ruz Veloso¹, German Rud¹, Felipe Pasquet¹ y Ailen Altamirano¹

¹ Facultad de Ciencias Exactas y Naturales (UBA)



Introducción


- El texto generado por sistemas de reconocimiento automático del habla suele carecer de puntuación y estar completamente en minúsculas, dificultando su lectura y posterior procesamiento.
- En este trabajo exploramos distintos modelos de machine learning para restaurar estos elementos de manera automática.

Objetivo

- Comparar tres algoritmos para predecir puntuación y capitalización en texto sin formato, e identificar al que logra el mejor desempeño.

Texto normalizado

los profesores dijeron
que no aprobaron
todos los trabajos



RF
LSTM
biLSTM

Texto restaurado


Los profesores dijeron
que no. Aprobaron
todos los trabajos.

Dataset

Utilizamos dos fuentes de texto en español, complementarias entre sí:

- TED Talks** (OPUS): subtítulos, representativos del registro oral.
- Tatoeba**: Conjunto colaborativo de oraciones en español, con mayor presencia de preguntas y ejemplos que contienen más de una oración.

Metodología



Resultados

Espacio De Búsqueda de Hiperparámetros

$$\Theta = \begin{cases} H_{size} \in \{128, 256, 512\} \\ N_{layers} \in \{1, 2, 3\} \\ P_{drop} \in \{0.3, 0.5\} \\ \eta \in \{0.001, 0.0005\} \\ \mathcal{W}_{loss} \in \left\{ \begin{pmatrix} 1, 1, 1 \end{pmatrix}, \begin{pmatrix} 1, 3, 1 \end{pmatrix}, \begin{pmatrix} 1, 5, 1 \end{pmatrix} \right\} \end{cases}$$


Se exploró el espacio de hiperparámetros Θ utilizando Random Search

Comparativa de Desempeño en el conjunto de Test

F1 macro	Random Forest	LSTM	BiLSTM
Puntuación inicial	0.59	0.8074	0.9025
Puntuación final	0.49	0.7560	0.8382
Capitalización	0.75	0.9026	0.9387

Para las LSTM se reportan los resultados de la mejor combinación de hiperparametros hallada

Arquitectura y Parámetros del Modelo con Mejor Desempeño



Validación del Modelo Seleccionado (biLSTM)

Resultados obtenidos al realizar predicciones sobre el conjunto Held-out utilizando el modelo de mejor performance

Puntuación inicial			
Clase	Precisión	Recall	F1-Score
NO	0.9979	0.9986	0.9982
SI (¿)	0.8274	0.7632	0.7940
Macro Avg	0.9126	0.8809	0.8961

Puntuación final			
Clase	Precisión	Recall	F1-Score
VACÍO	0.9854	0.9856	0.9855
PUNTO (.)	0.9178	0.9642	0.9404
COMA (,)	0.6549	0.5923	0.6220
SIGNO (?)	0.8242	0.7785	0.8007
Macro Avg	0.8456	0.8301	0.8372

Capitalización			
Clase	Precisión	Recall	F1-Score
MINÚSCULA	0.9927	0.9927	0.9927
TÍTULO (Mayus)	0.9511	0.9555	0.9533
OTRO (Mezcla)	0.9627	0.8753	0.9170
MAYÚSCULA (Todas)	0.9088	0.8658	0.8868
Macro Avg	0.9538	0.9223	0.9374

Conclusiones

- La arquitectura **biLSTM** demostró ser la **más robusta** para recuperar la estructura del texto, superando consistentemente al *baseline* (Random Forest).
- Se logró una **generalización efectiva** en datos no vistos (conjunto Held-out), alcanzando una F1 de 0.9374 en capitalización, 0.8961 en puntuación inicial y 0.8372 en puntuación final.
- La predicción de **comas** persiste como la **tarea más compleja**, limitada por su alta subjetividad y ambigüedad sintáctica.
- Futuros entrenamientos**: Incorporar oraciones truncadas puede ayudar a reducir la dependencia de los marcadores artificiales de borde en las distancias coseno (-1) al predecir puntos finales.

